실제 GPT: 패턴 전·후 비교

모의 응답이 아닌 실제 OpenAI API 결과입니다. 12사례 × 이해 확인·최종 응답 × 두 버전 = 48회. 총 토큰 비용 추정은 US$0.0748929입니다.

지표	패턴 전	패턴 후	관찰
Codex AI 평가 /100	74.38	78.96	+4.58점
최종 상담 품질 /100	66.67	74.58	+7.92점
출력 계약 통과	23/24	24/24	+1건
행동 배열 정확히 1개	4/10	10/10	+6건
평균 모델 호출	6.93s	6.97s	+0.5% 느림
평균 최종 상담	7.15s	8.29s	+16.0% 느림
24호출 비용·캐시 반영	US$0.0377581	US$0.0371348	-1.65%
24호출 비용·캐시 제외	US$0.0395725	US$0.0407060	+2.86%

효과와 한계

종합 품질 +4.58점 / 최종 상담 +7.92점. 사례별 개선 6개·동점 5개·하락 1개입니다. 공감 축은 3.000→2.958/4로 좋아지지 않았습니다. 품질 점수의 차이는 정답 정확도 향상률이 아닙니다.

동일 모델 gpt-5-mini-2025-08-07, reasoning low, 동일 입력·RAG·카드·스키마를 사용했습니다. Python SystemRandom으로 사례별 카드를 한 번 뽑아 두 그룹에 똑같이 제공했습니다. 이해 확인과 최종 응답을 독립 비교했고, 최종 단계에는 동일한 수동 확인 맥락을 넣었습니다. 앱의 종단간 대화·DB·화면 성능 실험은 아닙니다.

12개 합성 사례, 각 단계·버전당 한 번 생성한 탐색 비교입니다. 프롬프트를 작성한 Codex AI가 X/Y를 가리고 채점표를 고정한 뒤 매핑을 열었습니다. 별도 인간·전문상담가 평가는 없었습니다. 독립 평가·모집단 정확도·임상 효과나 통계적으로 확정된 향상률을 뜻하지 않습니다.

정확도와 전체 사례

공통 검사	전	후
제공 카드 ID·순서	10/10	10/10
일상 고민 검색 불필요 판단	12/12	12/12
명시적 경청 의도 분류	2/2	2/2
모호한 개인 용어 확인	1/1	1/1
경청 후속 질문 없음	1/2	2/2
현재 발화의 정의 인용 정확	0/1	0/1

12사례 모두 공개: 이해·최종 응답 평균

사례	전 /100	후 /100	차이
AB01 기여 인정	80.0	80.0	+0.0
AB02 친구의 취소	80.0	85.0	+5.0
AB03 계약 종료·경청	85.0	85.0	+0.0
AB04 오해 정정	75.0	82.5	+7.5
AB05 모호한 별칭	75.0	75.0	+0.0
AB06 개인사전·진행	70.0	67.5	-2.5
AB07 합격·불합격 친구	57.5	75.0	+17.5
AB08 가족 돌봄	77.5	77.5	+0.0
AB09 약속과 휴식	75.0	75.0	+0.0
AB10 질문 없는 경청	85.0	90.0	+5.0
AB11 면접·예측 요청	62.5	82.5	+20.0
AB12 이전 조언 실패	70.0	72.5	+2.5

감정 반영·사연 이해·선택권·근거·간결함을 각 0~4점, 합/20×100으로 평가했습니다. X/Y 점수를 먼저 고정한 뒤 매핑을 열었습니다. Codex AI의 단독 평가이며 독립적인 사람 평가와 구분합니다.

actions 한 개는 본문 전체의 행동 한 개가 아닙니다. 응답 모드 기대값 일치는 5/12→8/12였으나 명시적 조언 요청이 없는 문항에는 해석 여지가 있어 정답 정확도로 부르지 않습니다. 두 버전 모두 기존 RAG를 사용합니다.

실제 원문: 좋아진 부분

AB07 · 나는 합격, 친구는 불합격

나는 합격했는데 같이 준비한 친구는 떨어졌어. 기쁜데 그 친구 앞에서는 미안해서 아무 말도 못 하겠어.

패턴 전 · 30/100

공감: 합격의 기쁨과 친구에 대한 미안함이 동시에 드는 상황이시군요. 기쁘면서도 친구의 상실감이 떠올라 말이 잘 안 나올 수 있어요.
응답·조언: 먼저 진심으로 축하한다는 말과 함께 친구의 마음을 먼저 묻고 들어보세요. 기쁨을 과시하기보다 함께할 의지를 보여주고, 이후에 축하를 같이 즐길 수 있는 작은 제안을 해보세요.
행동: 짧게 축하 인사(예: "정말 축하해, 네가 많이 힘들었을 텐데")와 함께 먼저 친구의 기분을 묻기 / 친구가 이야기하기 힘들어하면 '괜찮을 때 얘기해'라고 말하며 기다려주기 / 나중에 둘이 함께할 소소한 약속(식사나 산책 한 번)을 제안하기
후속 질문: 원하시면 친구에게 건넬 짧은 문장 예시를 몇 가지 만들어 드릴까요?

패턴 후 · 65/100

공감: 합격해서 기쁜 마음과 친구에게 미안한 마음이 함께 있으실 텐데, 두 감정 모두 자연스러워요. 친구를 배려하는 마음이 크셔서 어떻게 전할지 고민되셨겠어요.
응답·조언: 친구에게는 먼저 감정을 인정하는 한마디를 전하고, 합격 소식은 조심스럽게 알리는 게 좋아요. 예: '네가 힘들었을 텐데 미안해. 나 합격했어, 괜찮을 때 얘기해도 될까?'처럼요.
행동: '네가 힘들었을 텐데 미안해. 나 합격했어, 괜찮을 때 얘기해줘.'라고 조심히 전해보기.
후속 질문: 친구에게 직접 말할 때와 메시지 중 어느 방식이 더 편하세요?

기존은 불합격한 친구에게 축하하라고 제안해 주체를 혼동했습니다. 변경 후 이 오류는 줄었지만, 합격을 미안하다고 사과하는 문구는 여전히 죄책감을 강화할 수 있습니다.

AB03 · 해결책보다 경청을 요청

패턴 전 · 80/100

공감: 계약이 끝나고 허전함과 쓸모없음이 밀려온 느낌, 정말 마음이 무거우셨겠어요. 지금은 해결책보다 그냥 들어주길 원하신다는 말씀 잘 이해했어요.
응답·조언: 원하시는 만큼 천천히 말씀해 주세요—제가 조용히 끝까지 들어드릴게요.
후속 질문: 지금부터 어떤 이야기부터 꺼내고 싶으세요?

패턴 후 · 85/100

공감: 계약이 끝난 뒤 허전함과 쓸모없다는 감정이 드는 게 얼마나 무거웠을지 전해져요. '그저 들어주길' 바라는 마음을 표현해 주신 것, 잘 받았어요.
응답·조언: 지금은 말을 꺼내는 것 자체가 힘이 되는 시간이에요. 원하시면 편하게 이어서 이야기해 주세요 — 제가 듣고 있을게요.

기존은 경청 요청 뒤에 다시 질문했습니다. 변경 후 질문을 붙이지 않았습니다. 전체 사례 점수는 이해 단계의 차이까지 합쳐 동점입니다.

공감·조언·행동·질문 필드를 원문 그대로 발췌했습니다. 카드별 전체 문장과 12사례의 전체 출력은 비교 화면·JSON에 있습니다.

회귀 사례와 비용의 실제 차이

AB06 · 개인사전의 등산 모임에서 첫 진행

패턴 전 · 70/100

공감: 말하기만 해도 주눅이 드는 느낌이시군요.
이해: 오름(내가 참여하는 등산 모임)에서 처음으로 진행을 맡으셨고, 경험 많은 분들 앞에서 말을 시작할 생각만 해도 위축되신다고 하셨습니다.

패턴 후 · 60/100

공감: 경험 많은 분들 앞에서 말해야 한다는 생각만으로도 많이 긴장되셨겠어요. 괜찮으시면, 그 모임에서 언제 어떤 자리로 진행을 맡으시게 된 건지 조금 들려주실래요?
이해: 오름(사용자 참여 등산 모임)에서 처음으로 진행을 맡게 되어 주눅 들고 긴장하심.

종합 70.0→67.5로 하락. 하락 사례입니다. 변경 후 공감 필드에 질문이 섞이고 요약이 메모체가 됐습니다. 두 버전 모두 사전 문장을 현재 사용자가 직접 말한 정의처럼 인용했습니다. 기존 서버 검사가 잘못된 인용의 기억 저장을 차단합니다.

항목	전	후	해석
입력 토큰	39,794	46,896	+17.85%
캐시 입력	8,064	15,872	조건 차이
청구 출력 토큰	14,812	14,491	-2.17%
그중 reasoning	6,784	7,616	중복 가산 없음
평균 이해 확인	6.72s	5.65s	-15.99%
최종 상담 p95	9.84s	11.90s	+20.88%

실제 사용 토큰에 확인일의 표준 단가를 적용했습니다. 100만 토큰당 입력 US$0.25 / 캐시 입력 US$0.025 / 출력 US$2.00입니다. reasoning은 output_tokens에 이미 포함돼 다시 더하지 않았습니다. 세금·계정 계약·웹 검색·음성·서버 비용은 제외한 청구 추정치입니다.

캐시 입력량이 달라 실제 캐시 기준 -1.65%를 고유한 절감 효과로 일반화하지 않습니다. 캐시가 없으면 비용은 +2.86%입니다. 2호출을 한 상담으로 가정한 1,000건 환산은 캐시 반영 약 US$3.15→US$3.09, 캐시 제외 약 US$3.30→US$3.39입니다.

다음 개선 후보

주체·시간 보존, 사전/현재 발화 출처 구분, 본문·카드에 숨은 여러 과제 축소를 우선 검토할 필요가 있습니다. 마이너 56장의 기본 뜻이 4개 템플릿인 입력 데이터 제약도 남습니다. 이번 결과를 본 뒤 제품·프롬프트·기존 테스트를 바꾸거나 실패를 재생성하지 않았습니다.

공식 모델·단가

48회 원본·전체 채점·비교 화면