여운 타로 상담 · 구현·검증 보고서

기준일: 2026-11-07 | 범위: 최근 AI 상담·RAG·화면 연결·성능 검증

1. 전부 완료했는가?

아직 전부 완료한 상태는 아니다. 상담 기능 구현과 코드 검증은 완료됐지만, 실제 GPT의 답변 품질·응답시간 검증과 iOS 실행 검증은 남아 있다.

항목	상태	확인한 내용
상담 흐름·화면	구현·코드 검증 완료	짧은 공감, 의미 확인·정정, 카드와 조언, 듣기·이어가기
타로 추첨	구현·코드 검증 완료	Python SystemRandom으로 1/3장 추첨, 중복 방지, 재시도 시 카드 유지
개인사전 RAG	구현·코드 검증 완료	본인 용어 검색, 최근 대화, 뽑힌 카드 의미를 모델 입력에 포함
임베딩·벡터 검색	미구현	현재 구현한 키워드 검색과 구분
실제 GPT 평가	미완료	서버 준비 상태 available=false, 실제 호출 0건
순차 성능 측정	내부 처리만 측정	사전 검색·대화 정리·카드 추첨. DB·네트워크·GPT 시간 제외
Git 반영	기능 브랜치 push 완료	백엔드·웹·RN 세 저장소. main 병합·운영 배포는 미실시

코드 검증 결과

대상	기존 실행 결과	이번 확인
FastAPI	전체 579 passed	원격 CI 통과, 상담 관련 38건도 격리 DB에서 통과
React 웹	133 passed	타입 검사·배포 빌드 CI 통과
RN CLI	136 passed	타입 검사·Android JS 번들 CI 통과

숫자는 앞서 실행한 코드 검사 결과다. 이번 보고서 작성에서 전체 테스트나 부하 테스트를 다시 실행하지 않았다. 통과 건수는 실제 GPT 답변 품질이나 모든 기능의 출시 완료를 뜻하지 않는다.

2. 사용자가 경험하는 상담

이야기 입력 → 짧은 공감 → 의미·입장 확인 → 카드 추첨 → 짧은 조언 하나 → 마음기록·이어가기

- “그것 때문에 너무 화나.” → “화가 많이 나셨겠어요. 괜찮으시면, 어떤 일이 있었는지 조금 들려주실래요?”
- 학생·직장인 등 사용자가 말한 입장에서 이해한 내용을 확인한다. 상대의 의도나 사용자의 잘못을 단정하지 않는다.
- 장학금 조회·메일 처리 같은 일반 정보 업무 대신 그와 관련한 마음과 고민을 묻는다.
- 일상 고민에는 웹 검색하지 않는다. 낯선 상담 개념이 정말 필요할 때만 최대 한 번 참고한다.
- 카드가 화면 위에 남아 있고 아래에서 짧은 조언을 읽는다. 참고 링크는 필요한 경우 펼쳐보도록 배치했다.
- 위 문장과 기존 화면 검수 이미지는 편집·합성 예시다. 실제 GPT 평가 결과로 제시하지 않는다.

3. RAG는 어떻게 사용했는가?

RAG는 본인 사전의 키워드 검색 결과·최근 대화·카드 의미를 참고한다.

임베딩·벡터 검색은 구현하지 않았다.

참고 정보	선택 방식	범위
개인사전	사용자 정의 용어를 정규화해 현재 문장에서 검색	본인 소유 사전, 관련 항목 최대 8개
대화 문맥	최근 기록을 길이 예산 안에서 선택	최대 10개 메시지·6,000자
타로 의미	서버에서 뽑힌 카드 ID의 기본 의미 사용	선택한 1장 또는 3장
외부 참고	상담 개념 확인이 필요한 경우에 한정	최대 1회 검색, 본인 대화 범위 캐시 10분

검색 코드의 핵심은 아래와 같다.

```
def retrieve_definitions(text, entries, limit=8):
    query = normalized(text)
    matches = [v for v in entries
               if normalized(v["term"]) in query]
    return sorted(matches,
                  key=lambda v: len(normalized(v["term"])),
                  reverse=True)[:limit]
```

출처: 개인사전 검색 코드, 상담 조합 코드.

아키텍처와 데이터 보호

React / RN 화면 → 별도 CounselingApi → FastAPI HTTP 어댑터 → 상담 유스케이스·도메인 → 포트 → PostgreSQL / OpenAI 어댑터

항목	반영 내용	확인의 한계
사용자 격리	서버 세션으로 사용자 결정, owner_id 입력 거부, DB RLS·제한 역할	코드·통합 검사 기준이며 외부 보안 감사는 아님
개인 기억	명시한 정의만 저장, 수정·삭제·대화 한정 기억	의미 유사도를 통한 장기 기억 검색은 없음
중복·실패 처리	요청 키 중복 방지, 재시도 시 카드·확인한 자료 유지	실제 제공자 장애·통신 환경 평가는 남음
동의·삭제	외부 호출 전 동의 재확인, 생성 중 삭제 시 후속 게시 차단	운영 환경 검증은 남음
초안·음성	계정별 메모리 초안, 기기 음성·검토한 전사 입력	초안은 앱 프로세스 종료 후 복구하지 않음

상담은 사용자를 지지하되 타인의 마음, 진단, 미래 결과를 카드로 확정하지 않는다. 확인된 카드 ID·참고 자료만 조합하도록 구조 검증을 넣었다.

4. 성능 측정: 부하 테스트 제외

동시 요청을 보내는 부하 테스트는 이번에 실행하지 않았다. 한 번에 하나씩 내부 함수를 실행해 처리시간만 확인했다.

조건: 로컬 Python 프로세스, 합성 사전 200개, 최근 대화 10개, 카드 78개 중 3장. 항목마다 준비 실행 5회 후 순차 50회 측정. 시간은 perf_counter_ns로 측정했다.

측정 항목	중앙값	p95	표본
개인사전 200개에서 검색	0.0177ms	0.0196ms	50회
최근 대화 10개 정리	0.0007ms	0.0008ms	50회
Python 카드 3장 추첨	0.0081ms	0.0088ms	50회

이 수치는 직전 성능 측정의 콘솔 기록이다. 함수 실행시간만 포함하며 DB 조회·프롬프트 전송·네트워크·GPT 생성·화면 렌더링은 포함하지 않는다. 실제 상담 전체 지연이나 다른 기기에서의 성능을 이 수치로 판단할 수 없다. 과거 부하 측정 기록은 보존하되 이번 성능 평가 결과에서 제외했다.

실제 AI 성능·품질의 현재 상태

항목	현재 상태
서버 준비 확인	HTTP 200, available=false
실제 OpenAI 호출	0건
첫 공감 답변까지의 시간	미측정
확인 후 최종 조언까지의 시간	미측정
상냥함·맥락 이해·RAG 활용 정확도	실제 모델 평가 미실시
50개 평가 예제	상담 중심으로 재작성 완료, 실제 모델 50건 평가 완료와 다름

기본 설정은 gpt-5-mini, reasoning effort low다. 출력 토큰 상한은 이해 확인 2000 / 최종 조언 2500 / 드문 개념 참고 900이다. 이는 설정 완료이며 실제 속도 개선이 입증됐다는 뜻은 아니다. 서버에서 모델·상한을 바꿀 수 있다.

실제 연결 후에는 동시성 1로 첫 공감·최종 조언의 시간을 나눠 측정한다. 입력에 "화나", "그냥 들어줘", "내 뜻은 그게 아니야"를 포함하고, 불필요한 검색 여부와 공감의 자연스러움을 함께 검토한다. 숫자·스키마 검사만으로 상담 품질을 합격 처리하지 않는다.

50개 평가 예제 · 평가 JSON · 실제 AI 미연결 기록 · 모델 설정

5. Git 반영과 TDD

세 저장소의 **codex/counseling-rag-20261107** 브랜치에 기능별로 커밋·푸시했다. 원격과 로컬 HEAD 일치를 확인했다. 아래 SHA는 보고서 갱신 직전 기준이다.

저장소	확인한 HEAD	원격 검증
tarobo22/taro-back	e05974f	FastAPI 전체 검사 통과
tarobo22/taro-raect	9a0489f	웹 타입·테스트·빌드 통과
tarobo22/taro	bc541a4	RN 타입·테스트·Android JS 번들 통과

백엔드 CI는 제품 코드 d38f885 기준이며, 이후 e05974f와 이번 갱신은 문서 변경만 포함한다.

기능 커밋에는 도메인·추첨 → 상담 유스케이스·사용자 격리 → HTTP API → RN·웹 연결 → 평가 자료 순서가 반영돼 있다. 새 기능의 의도된 RED를 확인한 뒤 구현·재검증했으며, 기존 베이스라인 테스트를 삭제·완화·skip하지 않았다. 모든 과거 커밋이 단독으로 완전한 RED→GREEN 증거를 담는다고 주장하지 않는다.

별도 iOS 시뮬레이터 CI는 확인 시점 대기 상태다. 이번 상담 변경의 실기기 실행·iOS 네이티브 검증·운영 배포·스토어 출시는 완료로 표시하지 않는다. 원본 폴더의 별도 App Store 미커밋 변경은 보존했다.

6. 남은 작업과 완료 기준

우선순위	남은 작업	완료 기준
1	서버 OpenAI 연결	준비 상태가 available=true이고 합성 입력으로 실제 호출 성공
2	실제 상담 품질·순차 성능 평가	공감·의미 정정·경청·RAG 사례 검토, 첫 답변·최종 조언 시간 기록
3	사용자 기기에서 상담 흐름 확인	텍스트·음성·카드 고정·재시도·계정 변경 동작 확인
4	출시 준비·iOS 확인	운영 환경·개발자 계정·네이티브 빌드 검증을 별도 완료

Vite 개발 모드의 기존 RN Flow 의존성 최적화 오류가 있어 화면 검수는 배포 빌드 미리보기로 진행했다. 관련 의존성 설정은 변경하지 않았다. 큰 JS 번들 경고와 테스트 의존성 경고도 별도 확인 대상으로 남아 있다.

이번 보고서 요청에서 변경한 파일

- docs/counseling/IMPLEMENTATION-20261107.md - 완료·미완료·RAG·순차 성능 보고
- docs/counseling/CHANGES.md - 보고서 변경 목록 추가
- docs/counseling/STATUS-20261107.pdf - 제출·열람용 PDF

제품 코드·테스트·설정·기존 사용자 변경은 이번 보고서 작성에서 수정하지 않았다. 부하 테스트와 실제 유료 API 호출도 실행하지 않았다. PDF 열람용 사본은 작업 공간의 output/pdf/yeoun-counseling-status-20261107.pdf에 둔다.

백엔드 기능 변경 목록 · 웹 변경 목록 · RN 변경 목록